

Prueba técnica

Líder e Ingeniero de Datos

Aspecto	Detalle
Rol evaluado	Líder e Ingeniero de Datos: estrategia, ingeniería, Azure y Fabric, ciencia de datos
Tiempo estimado de trabajo	8 a 10 horas efectivas. No esperamos ni valoramos más.
Fecha de envío	Miércoles
Fecha límite de entrega	Viernes 11:59 p.m. (hora Colombia, UTC-5) O antes si lo terminas.
Material adjunto	Un conjunto de datos único, generado solo para ti
Modalidad	Trabajo asincrónico + defensa técnica en vivo de 40 minutos
Uso de IA	Permitido y esperado, bajo las condiciones de la sección 2.3

Antes de empezar, lee esto. Esta prueba no busca una respuesta correcta. Busca entender cómo piensas. Los datos que vas a recibir se comportan como los datos reales: tienen problemas, y nadie te va a decir cuáles. La solicitud del comité también se parece a las reales: tiene peticiones que conviene cuestionar. Tu trabajo no es solo ejecutar, es decirnos qué ves.

1. Propósito de esta prueba

En DonDoctor estamos construyendo la función de datos desde su base. Hoy no existe un data warehouse: la información vive en las bases transaccionales de cada cliente y en los sistemas de mensajería. Buscamos a una persona que pueda definir la estrategia de datos, construir la plataforma que la soporte, y convertir los datos en servicios que generen valor para nuestros clientes y para el negocio.

La prueba evalúa siete competencias que consideramos inseparables en el rol:

#	Competencia	Qué observamos
1	Diagnóstico y calidad de datos	Si descubres lo que los datos no dicen de sí mismos, con evidencia
2	Estrategia y producto de datos	Si conectas los datos con decisiones, valor de negocio y límites legales
3	Arquitectura en Azure y Fabric	Si diseñas para multi-cliente, seguridad, costo y operación real
4	Ingeniería implementada	Si construyes pipelines que otro ingeniero podría operar y confiar
5	Ciencia de datos	Si modelas con rigor, validas con honestidad y ves los riesgos éticos
6	Comunicación ejecutiva	Si la gerencia puede decidir leyendo tu resumen
7	Proceso y colaboración	Cómo preguntas, cómo gestionas el compromiso y cómo documentas

Sobre el alcance: esta prueba está deliberadamente sobredimensionada respecto al tiempo disponible. No podrás hacerlo todo con profundidad. Esa es la prueba. Queremos ver qué priorizas, qué dejas fuera y por qué.

2. Reglas del ejercicio

2.1 Tiempo

Estimamos entre 8 y 10 horas de trabajo efectivo. Si vas por encima de 12 horas, probablemente estás intentando cubrir todo en lugar de priorizar. Registra tu tiempo real por bloque de trabajo: ese registro es parte de la evaluación.

2.2 Preguntas durante el ejercicio

Puedes escribirnos en cualquier momento. Respondemos en el transcurso del día. Las preguntas que hagas son parte de la evaluación: preguntar bien suma, no preguntar no suma. Algunas preguntas no las vamos a responder porque la decisión te corresponde; en ese caso te lo diremos.

2.3 Uso de inteligencia artificial

Puedes usar cualquier herramienta de IA. La condición es declararlo en un archivo USO-IA.md en tu repositorio, indicando:

- Qué herramientas usaste y en qué partes del ejercicio.
- Un ejemplo concreto de algo que la IA te propuso y que corregiste o descartaste, y por qué.

- Un ejemplo de algo que resolviste sin IA y por qué consideraste que no aportaba.

Importante sobre datos: aunque los datos son sintéticos, trátalos como si fueran reales. Cómo decidas usar herramientas externas con ellos también dice algo de tu criterio.

Lo que sí penalizamos: entregar contenido que no puedas explicar. En la defensa técnica te pediremos modificar tu propio código en vivo y justificar decisiones concretas. Si no puedes hacerlo, el resultado asincrónico se descarta.

2.4 Entorno y herramientas

No necesitas licencias ni acceso a sistemas de DonDoctor. Para la implementación usa el stack que domines: Python, SQL, DuckDB, PySpark, dbt, pandas o equivalente, en tu máquina local. Si tienes acceso a Microsoft Fabric, puedes usarlo; incluye en ese caso capturas y la exportación de tus elementos.

La arquitectura objetivo del entregable E3 sí debe diseñarse sobre Azure y Microsoft Fabric, porque es el ecosistema en el que opera DonDoctor.

2.5 Tu conjunto de datos es único

El conjunto de datos adjunto fue generado exclusivamente para ti. Las cifras de cada candidato son distintas. Por favor no lo compartas.

3. El caso

3.1 Contexto de negocio

DonDoctor opera la gestión de citas de IPS y clínicas en Colombia: agendamiento por voz, web, WhatsApp y contact center, recordatorios, confirmaciones y reprogramación. Cada cliente tiene su propia base de datos transaccional en SQL Server. Los eventos de mensajería se guardan en MongoDB. El ecosistema tecnológico es Azure.

El ausentismo, es decir, que el paciente no llegue a su cita, es uno de los problemas más costosos del sector: es una hora de agenda médica perdida y un paciente sin atender. DonDoctor tiene una línea de producto orientada a reducirlo y otra de inteligencia operacional para las IPS. Ambas dependen de datos confiables que hoy no existen de forma consolidada.

3.2 Acta del comité de dirección

Esta es el acta de la reunión en la que se originó tu tarea. Está transcrita tal como fue enviada. No la hemos editado.

ACTA — Comité de dirección | Junio de 2026 | Tema: ausentismo y datos

Asistentes: Gerencia General, Dirección Comercial, Dirección de Operaciones, Dirección de TI.

Gerencia General

Necesitamos saber cuál es el ausentismo real de nuestros clientes. No podemos seguir con cifras distintas en cada reunión. También queremos un modelo que prediga qué pacientes no van a asistir para intervenir antes. Lo ideal es tenerlo en tiempo real.

Dirección Comercial

Nuestro cálculo da un ausentismo promedio entre 12 y 14%, que es bueno frente al mercado. Proponemos dos servicios nuevos: un benchmark donde cada IPS vea su ausentismo comparado con el de las demás IPS clientes, y un informe mensual para las EPS con el listado de sus afiliados con alto riesgo de inasistencia, para que ellas hagan gestión. Las EPS ya mostraron interés en pagar por eso. Queremos presentarlo en dos meses.

Dirección de Operaciones

El ausentismo real está más cerca del 15 al 17%. Comercial lo calcula distinto. Necesitamos un tablero para decidir dónde intervenir primero. Por lo que vemos, la IPS Sur es la que peor está y debería ser la primera.

Dirección de TI

Tenemos una extracción piloto de tres IPS y de los eventos de WhatsApp. No hay data warehouse. Tenemos licenciamiento Microsoft y estamos evaluando Fabric como plataforma. Accesos y seguridad de la extracción se revisarán después.

Acuerdo: solicitar al área de Datos una propuesta que responda a lo anterior, usando la extracción piloto.

3.3 Datos entregados

Recibirás un archivo comprimido con la extracción piloto:

Archivo	Origen simulado	Contenido
ips_norte_citas.csv	SQL Server, base del cliente IPS Norte	Citas de un año
ips_sur_citas.csv	SQL Server, base del cliente IPS Sur	Citas de un año
ips_occidente_citas.csv	SQL Server, base del cliente IPS Occidente	Citas de un año
whatsapp_eventos.jsonl	MongoDB, colección de eventos	Eventos de recordatorios
diccionario_datos.md	Equipo de TI	Descripción de los campos

Trata el diccionario de datos como lo tratarías en tu primer día de trabajo: como un punto de partida escrito por personas ocupadas, no como una verdad garantizada.

4. Entregables

Son seis entregables, ordenados por peso. Si el tiempo no alcanza, prioriza y dinos qué dejaste fuera y por qué.

E1. Diagnóstico y calidad de datos · 20%

Antes de construir, entiende lo que tienes. Entrega:

- **Perfilamiento:** volumen, completitud, distribución y consistencia de cada fuente, y de las fuentes entre sí.
- **Hallazgos:** cada problema que encuentres, con su evidencia cuantitativa (cuántos registros, qué porcentaje), su impacto sobre las métricas o el negocio, y el tratamiento que propones.
- **Reglas de calidad:** las reglas que implementarías para que el problema no vuelva a pasar sin ser detectado.
- **Preguntas al dueño del dato:** máximo 8, priorizadas, redactadas como las enviarías realmente.

Cada hallazgo debe estar respaldado por una consulta o fragmento de código reproducible en tu repositorio.

E2. Estrategia y producto de datos · 15%

Documento de máximo 4 páginas que responda al comité. Debe incluir como mínimo:

- La definición de ausentismo que recomiendas, por qué, y cómo gobernarías esa definición para que no vuelva a haber dos cifras.
- Tu posición sobre los dos servicios que propone Comercial, con su análisis de valor, riesgo legal y riesgo ético. Puedes recomendar lanzarlos, rediseñarlos o no lanzarlos: lo que importa es el argumento.
- Un producto o servicio de datos que tú priorizarías, cómo validarías que alguien paga por él antes de construirlo, y cómo medirías su éxito.
- Tu respuesta a la solicitud de tiempo real.
- Una hoja de ruta de 90 días con entregables concretos y los indicadores de negocio con los que medirías el valor de la función de datos.

E3. Arquitectura objetivo en Azure y Fabric · 15%

Un diagrama y un documento de decisiones de máximo 3 páginas. Debe abordar:

- Cómo ingieres las bases SQL Server de cada cliente y la colección de MongoDB sin afectar la operación.
- La organización por capas y el modelo de datos canónico para muchos clientes con esquemas que no son idénticos.
- Cómo garantizas que los datos de cada cliente y los datos sensibles de pacientes solo sean visibles para quien corresponde.
- Una estimación de capacidad y costo con sus supuestos explícitos, y cómo evitarías que una carga pesada afecte los tableros de gerencia.
- Cómo manejarías ambientes de desarrollo, pruebas y producción.
- Cómo consumirían estos datos los agentes y modelos de IA de DonDoctor de forma trazable.
- Qué NO harías en Fabric y por qué.

E4. Pipeline implementado · 20%

Construye un pipeline funcional sobre la extracción piloto, en el stack que domines.

Requisitos funcionales

- Ingesta de las cuatro fuentes a una capa cruda que preserve el dato original.
- Una capa limpia con un modelo canónico unificado para las tres IPS, con los problemas de E1 tratados.
- Una capa de consumo con al menos una tabla de hechos de citas, sus dimensiones, y la métrica de ausentismo según la definición que recomendaste en E2.
- Pruebas automatizadas de calidad de datos que fallen cuando algo se sale de lo esperado.
- El pipeline debe poder ejecutarse dos veces seguidas sin duplicar datos.
- Tratamiento explícito de los datos personales y sensibles en cada capa.

Requisitos de proceso

- **Repositorio Git público** con historial real: mínimo 6 commits incrementales con mensajes descriptivos. Un único commit con todo el código descalifica este entregable.
- **No subas los datos al repositorio.** Documenta dónde deben ubicarse para ejecutar.
- **README** con instalación, ejecución, decisiones de diseño, limitaciones conocidas y qué harías con dos semanas en lugar de un fin de semana.

E5. Modelo predictivo de ausentismo · 15%

Un cuaderno o script reproducible que construya un primer modelo para predecir la inasistencia. Debe incluir:

- La decisión de negocio que el modelo habilita y el momento exacto en que se haría la predicción.
- La definición de la variable objetivo y la justificación de cada variable que usas o descartas.
- Un modelo base simple y, si lo consideras útil, uno más elaborado.
- Una estrategia de validación coherente con el uso real del modelo.
- La métrica principal que reportas y por qué confías en ella.

- Un análisis del comportamiento del modelo entre grupos de pacientes y su implicación para el uso responsable.
- Tu recomendación: para qué usar este modelo y para qué no usarlo.

E6. Resumen ejecutivo y video · 10%

Resumen ejecutivo de una página dirigido a la Gerencia General, que responda de forma directa tres preguntas: cuál es el ausentismo real, en qué IPS intervenir primero, y si se deben lanzar los servicios que propone Comercial.

Video de 6 a 8 minutos compartiendo pantalla, sin diapositivas y sin guion leído, que responda:

- ¿Qué fue lo que más te sorprendió de los datos y cómo lo descubriste?
- ¿Cuál fue la decisión más difícil y por qué la tomaste así?
- ¿Qué dejaste fuera y qué harías primero con 4 horas más?
- Elige un fragmento de tu código y explica por qué está escrito así.
- Una situación real de tu experiencia en la que tuviste que decir que no, o que todavía no, a una solicitud de datos de un área de negocio.

5. Formato y canal de entrega

Envía un único correo con el asunto:

Prueba tecnica Datos - [Tu nombre completo]

Elemento	Formato	Obligatorio
Enlace al repositorio Git público	URL	Sí
Documento con E1, E2, E3 y el resumen ejecutivo de E6	PDF único	Sí
Diagrama de arquitectura	Imagen o PDF, dentro del documento	Sí
Cuaderno o script del modelo (E5)	En el repositorio	Sí
Enlace al video	URL accesible sin registro	Sí
Declaración de uso de IA	USO-IA.md en el repositorio	Sí
Registro de tiempo por bloque	Sección dentro del PDF	Sí
Exportación de elementos de Fabric	En el repositorio	Solo si usaste Fabric

Fecha límite: domingo, 11:59 p.m. hora de Colombia (UTC-5).

Si no vas a alcanzar a entregar todo, entrega lo que tengas antes del plazo con una nota del estado. Una entrega parcial honesta y a tiempo se evalúa mejor que una entrega tardía.

6. Cómo te vamos a evaluar

Frente evaluado	Peso	Qué distingue a un candidato sobresaliente
E1. Diagnóstico y calidad	20%	Encuentra problemas que no están escritos en ninguna parte y los demuestra con evidencia
E2. Estrategia y producto	15%	Conecta cada propuesta con valor, riesgo legal y riesgo ético; sabe cuándo decir que no
E3. Arquitectura Azure y Fabric	15%	Diseña para multi-cliente, seguridad y costo, y sabe qué no hacer
E4. Pipeline implementado	20%	Código que otro ingeniero podría operar y en el que la gerencia podría confiar
E5. Modelo de ausentismo	15%	Rigor en la validación, honestidad sobre los resultados y criterio en el uso
E6. Resumen y video	10%	La gerencia decide leyendo una página; explica su razonamiento con naturalidad

Frente evaluado	Peso	Qué distingue a un candidato sobresaliente
Proceso y colaboración	5%	Calidad de las preguntas, del historial de commits y de la gestión del compromiso

Lo que NO evaluamos:

- La herramienta que elijas para implementar. Cualquiera sirve si la usas bien.
- La complejidad del modelo. Un modelo simple bien validado vale más que uno sofisticado mal validado.
- El diseño gráfico de los documentos.
- Que completes el 100% del alcance.

7. Fase 2 — Defensa técnica

Los candidatos que avancen serán convocados a una sesión en vivo de 40 minutos:

Momento	Duración	Qué haremos
Recorrido de tu entrega	10 min	Preguntas sobre decisiones concretas de tu código, tus datos y tus documentos
Trabajo en vivo	15 min	Te pediremos modificar o extender tu pipeline o tu modelo, compartiendo pantalla
Conversación de escenario	15 min	Una conversación sobre estrategia y negociación con áreas de negocio

No necesitas prepararte más allá de conocer bien lo que entregaste.

8. Contacto

Para preguntas sobre el ejercicio:

[correo de contacto]

Una última cosa.

Sabemos que un fin de semana es tiempo tuyo, y lo valoramos. Diseñamos este ejercicio para que te lleves algo útil, independientemente del resultado. Si en algún momento consideras que algo no es razonable o no está claro, dínoslo. Esa conversación también nos dice mucho, y en el buen sentido.